

תקינות נתונים (30 נקודות)

- a. על פי רוב full_name אינו מהווה מזהה יחודי של אדם.
- הציעו דרך לאתר מקרים בהם יש במערכת אנשים שונים באותו השם.
 - נמקו את ההגיון של הדרך שהצעתם.
 - ממשו את הדרך.
- b. טבלת incidents מכילה פרטי מידע מטבלאות אחרות, כגון subjects.
- האם הייתם בוחרים ליצג את המידע כ json? נמקו.
 - כיתבו רשומת דוגמה המציגה את ה subjects בצורת json. הסבירו מדוע בחרתם בצורת יצוג ספציפית זו.
 - שדה subject הוא מסוג varchar. מה התועלת בהפיכתו לסוג json?
- c. הסכמה המוצעת עצובה ומלאה בעיות כרימון. אנא ציינו 3 בעיות בסכמה. עבור כל בעיה ציינו:
- מה הבעיה הטכנית?
 - כיצד היא עשויה לפגוע במערכת?
 - האם הבעיה מהווה הפרה של כלל נורמליזציה ואם כן, איזה.
 - כיצד ניתן לפתור את הבעיה?
 - מה התועלת בעיצוב הנוכחי, אשר יתכן ובגלל בחרו בו.
- d. **בונוס:** בהערכה של ביצועי מודלים יש להפריד בין נתוני train עליהם נבנים המודלים ונתוני test עליהם המודלים נבדקים. אם בודקים על נתוני ה train לרוב הביצועים מוטים למעלה בשל over-fitting.
- האם אי חלוקה של נתוני ה GS בפרוייקט ל train & test היא בעיית איכות נתונים? נמקו.
 - האם יש הטיה במדידת מודל של זוגות סרטים של אותו הבמאי? ובמודל של collaborative filtering?
 - דרכים מקובלות לבצע את החלוקה הן
 - חלוקה קשיחה מראש (לדוגמה חלוקה לשתי טבלאות)
 - הסתרת נתוני ה test
 - מתן סט נתונים גדול הכולל את נתוני ה test ועוד אחרים (לדוגמת Netflix Prize בה רק הם ידעו על מה המודלים נמדדים).
 - שימוש בדגימה אקראית על ידי החוקר.
 - ביחרו את אחת הדרכים למעלה וציינו את יתרונותיה וחסרונותיה.

תשובה לדוגמה

a. רשומות השונות במין או בגזע מייצגות ככל הנראה אנשים שונים.

```
Select a.full_name
, a.case_number
, b.case_number
From
Officers as a
Join
```

Officers as b
On
a.full_name = b.full_name
Where
(a.race != b.race)
Or (a.gender != b.gender)

B.

i.

זוהי דילמה ויש טיעונים לעיצובים שונים וטובים. לאור קיומה של טבלה נפרדת היה עדיף להמנע מהכפילות. אם יש צורך בנתונים משתנים או דלילים (לדוגמה, שלל נתונים בליסטים), יש תועלת בשימוש בשדה json בטבלת ה subjects

li.

מכיוון שמדובר ב subjects ברבים, כדאי להשתמש במערך. ישנה דילמה האם ליצג רק את המפתח (השם המלא) או עוד פרטים. יצוג עוד פרטים יגדיל את הכפילות ויקל על השימוש.

דוגמה למערך שמות מלאים

```
[ "John Dow", "John Smith" ]
```

lii.

כאשר השדה מסוג json נאכפת הגנה על תקינות הפורמט ואי אפשר להזין טקסט שאינו מתאים לו

C.

בעיה ראשונה subjects & officers אינם מיוצגים כישות עצמאית

1. אלו ישויות יסוד והן מופיעות רק בהקשר של תיק.
2. אנחנו לא יכולים ליצג את פרטי האדם עצמאית.
3. אין בעית נורמליזציה. נורמליזציה לא עוסק באובייקטים שצריך ליצג.
4. להפריד את פרטי האדם לטבלה עצמאית ולהשתמש ב FK אליה בהקשר של תיק.
5. אם אין חשיבות לאדם, עדיף לשמור רק את שמו (נפוץ במקרים כמו שם מדינה). לאור יצוג מין וגזע, לא נראה שזה המקרה.

בעיה שניה subjects & officers גם בטבלה וגם בשדה

1. כפילות נתונים
2. עלולות להיות סתירות בין המקורות השונים ולא נדע מי הנכון. בנוסף, מבוזבז מעט שטח אחסון.
3. לא, כללי הנורמליזציה לא עוסקים בקשרים בין טבלאות שונות
4. להסיר את אחד מהמקור

5. זו החלטה רעה במיוחד וקשה להגן עליה. אם דאלאס עתירת אירועי ירי, סיכום בשדה יכול להאיץ ביצועים בשליפת מקרה.

בעיה שלישית שם מופיע גם כשם מלא וגם כחלקיו

1. כפילות נתונים
2. עלולות להיות סתירות בין המקורות השונים ולא נדע מי הנכון. בנוסף, מבוצע מעט שטח אחסון.
3. כן, תלות בן שדות. שימו לב שלפי שם מלא ניתן לדעת שם פרטי ויש תלות אבל לא בכיוון השני.
4. רצוי לשמור רק את השם הפרטי ושם המשפחה ולהרכיב מהם את השם המלא. עדיף לשמור את חלקי השם ולא את המלא כי אז אנו נמנעים מחוסר וודאות. לדוגמה, שם מלא בן שלושה חלקים כשאנו לא יודעים האם המרכזי הוא שם שני או שם נעורים.
5. יתכן שיש שמות מורכבים (ג'ורג בוש הבן, הנרי השמיני) ואנו רוצים לתמוך בהן. יתכן שיש התממשקות למערכות חיצוניות שכל אחת מהן עובדת לפי יצוג שונה לשם.

D.

i.

זו אינה בעיה נתונים אלא בעיה שימוש בנתונים שהחוקר יצר. ניתן לראות זאת שכן אין אף רשומה שאנחנו יכולים "לתקן" כדי למנוע את הבעיה.

ii.

שני סרטים ישארו של אותו הבמאי ללא קשר ליתר הרשומות. לעומת זאת, אם נשתמש בנתוני ה test על "אנשים שאהבו את א, אהבו גם את ב" הערכת הביצועים תהיה מוטת למעלה.

iv.

נתייחס לדגימה אקראית של נתוני train & test שכן זו שיטה נפוצה ביותר. בשיטה זו שתי קבוצות הנתונים צפויות ליצג את אותה האוכלוסיה וללא הטיה מובנית. יש לשמור את אופן הדגימה (לדוגמה seed) אולם ככל שהניסוי מורכב יותר הסיכוי לטעות בכך גדול יותר. לרוב לא מבצעים ניסוי יחיד. אם מגרילים שוב, ערבבנו נתוני train & test. אם משאירים את החלוקה, יש דליפת נתונים דרך מוחו של החוקר (כיוון מסויים עובד, נלך בו עוד) שיוביל בסופו של דבר להערכת יתר.