

Databases for data analytics

מועד א 2026

מבוא

משך הבחינה: 3 שעות

חומר עזר:

1. דף נוסחאות המגיע עם המבחן
2. מילון, לצרכי סטודנטים הרוצים להימנע משגיאות כתיב. שימו לב, **זהו מבחן חשיבה**. לא יורדו נקודות על שגיאות כתיב.


ישנם כמה סעיפי בונוס של חמש נקודות. הבונוסים הם מבוססים על הנלמד בקורס אבל ברמה גבוהה מהרגיל. מומלץ לנסות לענות על הבונוסים אולם **רק לאחר שפתרתם את כל הבחינה**.

בהצלחה!

סכמה

השאלות בבחינה תתייחסנה לסכמה של [Dallas](#), אירעי ירי במשטרת דאלאס, המובאת בתרשים למטה.

1. ניתן להניח ששדות case_number הם מפתחות בטבלה, או קשורים למפתח בטבלה אחרת.
2. פרשנות שמות השדה היא לרוב מילולית. אם אתם לא בטוחים בפרשנות, ציינו את הפרשנות שבחרתם מפורשות ונמקו אותה.



1. שליפות (30 נקודות)

במהלך הבחינה מותר, ואפילו רצוי, להשתמש בשאילתות שכתבתם קודם. כדאי לעשות זאת אנא השתמשו ב views וציינו בשאילתה המשתמשת את המקום בו הגדרתם אותה.

במידה ויש סעיף שהתקשתם בפיתורו, אתם יכולים לציין שם של view שפותר אותו, לכתוב מה השדות בו, ולהשתמש בו בסעיפים אחרים.

בשאלה זו ניתן להניח ש full_name הוא מזהה יחודי של אדם.

- a. שילפו את ה officer_count המקסימלי של incidents
- b. שילפו incidents בהם אותו אדם הוא גם officer וגם subject. חישוב על use case משטרתי וביחרו בהתאמה את השדות הנשלפים.
- c. שילפו את ה incidents שלא מעורב בהם officer ממין 'M'.
- d. שילפו את התפלגות מספר ה subjects מ race מסוג 'W' לכל incidents, כולל אלו שאין להם כאלו subjects. כלומר, מספר הפעמים ש incidents עירב 0, 1, 2, 3 וכדומה כאלו subjects ממוינים בסדר עולה.
- e. שילפו את מספר ה incidents לפי ה race, gender של המעורבים בהם. הציגו גם את ההסתברות לפי race ואת ההסתברות לפי gender. **רמז:** window functions יכולות להועיל.
- f. שאלת תקינות שאילתה, ללא קשר לסכמה זו. ציינו לפחות 3 סיבות בגללן השאילתה הבאה עשויה להכשל:

```
INSERT INTO target_table VALUES
( 1
, -1
, CURRENT_DATE()
, 'I saw a great movie about databases today.I can't wait for the SQL.'
, NULL
);
```

g. **בנוס:**

- i. שילפו כמחרוזת את צוותי ה officers של incidents בעזרת group_concat (חתימת כרטיסים).
- ii. שילפו את מספר incidents לצוות.
- iii. שילפו את ה distribution של הסעיף הקודם.
- iv. **רמז:** אבסטרקציה היא חברה שיכולה לעזור לכם. השתמשו ב views כדי להוריד את המורכבות.
- v. **המלצה:** זו שאלה קשה. גשו אליה רק אחרי שעניתם ובדקתם היטב את המבחן.

2. תקינות נתונים (30 נקודות)

- a. על פי רוב full_name אינו מהווה מזהה יחודי של אדם.

- i. הציעו דרך לאתר מקרים בהם יש במערכת אנשים שונים באותו השם.
 - ii. נמקו את ההגיון של הדרך שהצעתם.
 - iii. ממשו את הדרך.
- b. טבלת incidents מכילה פרטי מידע מטבלאות אחרות, כגון subjects.
- i. האם הייתם בוחרים ליצג את המידע כ json? נמקו.
 - ii. כיתבו רשומת דוגמה המציגה את ה subjects בצורת json. הסבירו מדוע בחרתם בצורת יצוג ספציפית זו.
 - iii. שדה subject הוא מסוג varchar. מה התועלת בהפיכתו לטוג json?
- c. הסכמה המוצעת עצובה ומלאה בעיות כרימון. אנא ציינו 3 בעיות בסכמה. עבור כל בעיה ציינו:
1. מה הבעיה הטכנית?
 2. כיצד היא עשויה לפגוע במערכת?
 3. האם הבעיה מהווה הפרה של כלל נורמליזציה ואם כן, איזה.
 4. כיצד ניתן לפתור את הבעיה?
 5. מה התועלת בעיצוב הנוכחי, אשר יתכן ובגלל בחרו בו.
- d. **בונוס:** בהערכה של ביצועי מודלים יש להפריד בין נתוני train עליהם נבנים המודלים ונתוני test עליהם המודלים נבדקים. אם בודקים על נתוני ה train לרוב הביצועים מוטים למעלה בשל over-fitting.
- i. האם אי חלוקה של נתוני ה GS בפרוייקט ל train & test היא בעיית איכות נתונים? נמקו.
 - ii. האם יש הטיה במדידת מודל של זוגות סרטים של אותו הבמאי? ובמודל של collaborative filtering?
 - iii. דרכים מקובלות לבצע את החלוקה הן
 1. חלוקה קשיחה מראש (לדוגמה חלוקה לשתי טבלאות)
 2. הסתרת נתוני ה test
 3. מתן סט נתונים גדול הכולל את נתוני ה test ועוד אחרים (לדוגמת Netflix Prize בה רק הם ידעו על מה המודלים נמדדים).
 4. שימוש בדגימה אקראית על ידי החוקר.
 - iv. ביחרו את אחת הדרכים למעלה וצינו את יתרונותיה וחסרונותיה.

3. עיצוב (30 נקודות)

עצבו בסיס נתונים עבור אחד מהמונדיאלים עד 2026, בו היו 32 נבחרות. המערכת צריכה לתמוך בשימושים הבאים.

1. ייצוג בתיים, group stage, ארבע נבחרות (בדיוק) המתחרות בניהן. כל נבחרת משחקת משחק אחד בדיוק מול כל חברה אחרת בבית.
2. שתי המנצחות בכל בית עולות לטורניר, knockout stage. הטורניר הוא עץ משחקים. יש מיפוי מראש של מקום בכל בית ועלה בעץ הטורניר. המנצחת במשחק עולה לשלב הבא.
3. יצוג הטורניר - משחקים של גמר, חצי גמר, רבע גמר, ושמינית גמר. כדי להמנע משנים של ויכוחים, יש לוודא שלא ניתן להזין יותר מגמר אחד וכדומה. יש ליצג מראש את הנבחרות במשחק (לדוגמה, בגמר ישחקו המנצחות בחצי הגמר) ובפועל (לדוגמה, המנצחת היא ברזיל).

4. העולות לטורניר הן המנצחות בשלב הבתים.
5. המשחקים מתבצעים באצטדיונים שונים הנמצאים בערים ומדינות שונות.
6. ניתן לחשב את המנצחים בבתים ובטורניר.
7. זו שאלה על בסיסי נתונים, לא על כדורגל. המנעו מפינות וקרנות. מותר לכם להניח הנחות על המונדיאל. ציינו אותן מפורשות ונמקו.

1. כיתבו קוד ליצירת הטבלאות הנדרשות. הקפידו על נרמול.
2. פרטו ונמקו את כל ההחלטות העיצוביות שקיבלתם:
 - a. ציינו מה כל הישויות שאתם מייצגים, מה התרחיש בשבילו הם נדרשים, ומה היצוג שנבחר. אם יש ישויות רלוונטיות שאתם לא מייצגים ציינו והסבירו למה.
 - b. הסבירו את השדות שבחרתם, התרחיש לו הם נדרשים, והטיפוס שבחרתם להם.
 - c. נמקו את המפתחות שבחרתם, האם הם טבעיים (קיימים בעולם האמיתי) או פנימיים (לדוגמה auto increment)
 - d. ציינו מה היחסים בין הישויות (1:1, 1:n, או n:n) בעולם האמיתי. אם בחרתם ליצג יחס אחר, ציינו ונמקו. מספיק לציין יחסים רק בין ישויות שכנות, שיש בניהן קשר ישיר.
 - e. פרטו מה ה constraints (לדוגמה: unique, FK, not null, check) שבחרתם ומה ההגנה שהם מספקים. אם יש נקודות שלא מוגנות על ידי בסיס הנתונים ציינו אותן ונמקו איך להגן.
3. הסבירו ונמקו את היצוג של 4 נבחרות בדיוק בקבוצה
4. הסבירו ונמקו מעבר מהבתים לטורניר (כלומר, המנצחת בבית A תשחק מול מספר שתיים בבית B, כמשחק 7 בשש-עשרית הגמר) ואת המעבר בין שלבי הטורניר (המנצחת בחצי גמר A תשחק מול המנצחת בחצי גמר B במשחק הגמר).
5. כיתבו שאילתה המוודאת שאין נבחרת שמשחקת בשתי מדינות שונות בהפרש של יום
6. **בנוסף:** הועלתה דרישה חדשה, לאחסן את המידע על המונדיאלים לדורותיהם במערכת. בעוד שבעבר במונדיאל השתתפו 32 מדינות, במונדיאל הנוכחי משתתפות 48 מדינות, מספר שאינו חזקה של שתיים. הסבירו כיצד תתמכו בכך, תוך הגנה של תקינות הנתונים.

4. שיפור ביצועים (10%)

השאלתה הבאה נכתבה לבסיס הנתונים IMDB מהקורס. מטרת השאלתה היא לשלוף רשימת הבמאים העצובים, כאלו שמעולם לא ביימו קומדיה.

```
select *
from
directors as d
join
movies_directors as md
on
d.id = md.director_id
```

```
where
md.movie_id not in
( select distinct movie_id
from
movies_genres
where
genre = 'Comedy'
order by
movie_id
)
;
```

הציעו לפחות 3 תיקונים ושיפורים לשאילתה. אתם יכולים ליצור טבלאות נוספות ולהגדיר אינדקסים במידה שיועילו לכם.

1. עבור כל שינוי
 - a. ציינו מה הבעיה שהוא מתקן.
 - b. ציינו חסרונות אם יש.
2. כיתבו את השאילתה המתוקנת.