

רעיונות למערכת המלצות – שאלה 2: שחקנים תחליפיים

מטרת השאלה היא לאתר זוגות של שחקנים שהם תחליפיים: שני שחקנים שלא שיחקו זה עם זה, אך קיימים שחקנים אחרים ששניהם שיחקו איתם. לדוגמה, אם R1 שיחק עם C וגם R2 שיחק עם C, אך R1 ו-R2 לא שיחקו יחד – R1 ו-R2 הם מועמדים להיות שחקנים תחליפיים.

2.1 מציאת זוגות של שחקנים תחליפיים

בשלב הראשון נשתמש בטבלת הזוגות משאלה 1. מאחר שבטבלת actor_pairs כל זוג נשמר רק בכיוון אחד, ניצור טבלה שבה כל קשר בין שחקנים מופיע בשני הכיוונים. כך ניתן יהיה לבדוק בצורה פשוטה אילו שותפים משותפים יש לכל שני שחקנים

```
CREATE TABLE actor_partners AS
SELECT actor_1 AS actor_id,
       actor_2 AS partner_id
FROM actor_pairs
```

UNION

```
SELECT actor_2 AS actor_id,
       actor_1 AS partner_id
FROM actor_pairs;
```

כעת נמצא זוגות של שחקנים שיש להם לפחות שותף משותף אחד, אך הם עצמם אינם שותפים. התנאי מונע קבלת אותו זוג פעמיים בסדר הפוך >

```
CREATE TABLE substitute_actors AS
SELECT
    roles1.actor_id AS actor_1,
    roles2.actor_id AS actor_2,
    COUNT(DISTINCT roles1.partner_id) AS common_partners
FROM actor_partners AS roles1
JOIN actor_partners AS roles2
    ON roles1.partner_id = roles2.partner_id
   AND roles1.actor_id < roles2.actor_id
WHERE NOT EXISTS (
    SELECT 1
    FROM actor_partners AS roles3
    WHERE roles3.actor_id = roles1.actor_id
      AND roles3.partner_id = roles2.actor_id
)
GROUP BY
    roles1.actor_id,
    roles2.actor_id;
```

2.2 ביצוע הניתוח לפי שאלה 1

בשאלה 1 מדד Jaccard לפי קבוצות הסרטים של שני השחקנים. כאן, מאחר מחפשים שחקנים תחליפיים, נחשב את המדד לפי קבוצות השותפים שלהם. ככל ששני שחקנים חולקים חלק גדול יותר מהשותפים שלהם, כך הם דומים יותר מבחינת רשת שיתופי הפעולה שלהם:

ראשית נחשב את מספר השותפים הכולל של כל שחקן

```
CREATE TABLE actor_partner_count AS
SELECT
    actor_id,
    COUNT(DISTINCT partner_id) AS total_partners
FROM actor_partners
GROUP BY actor_id;
```

לאחר מכן נחשב את מדד Jaccard לכל זוג שחקנים תחליפיים

```
SELECT
    substitutes.actor_1,
    substitutes.actor_2,
    substitutes.common_partners,
    substitutes.common_partners * 1.0 /
    (
        count1.total_partners
        + count2.total_partners
        - substitutes.common_partners
    ) AS jaccard
FROM substitute_actors AS substitutes
JOIN actor_partner_count AS count1
    ON substitutes.actor_1 = count1.actor_id
JOIN actor_partner_count AS count2
    ON substitutes.actor_2 = count2.actor_id
WHERE substitutes.common_partners * 1.0 /
    (
        count1.total_partners
        + count2.total_partners
        - substitutes.common_partners
    ) > 0.5
ORDER BY jaccard DESC;
```

מדד Jaccard מחושב כך

Jaccard = מספר השותפים המשותפים / (מספר השותפים של שחקן 1 + מספר השותפים של שחקן 2 - מספר השותפים המשותפים)

התנאי $Jaccard > 0.5$ משאיר רק זוגות שבהם יותר ממחצית מקבוצת השותפים המאוחדת שלהם היא משותפת. לכן הוא מסנן זוגות שחולקים שותף אחד במקרה, ומשאיר זוגות בעלי דמיון גבוה יותר בדפוסי שיתופי הפעולה שלהם.

המשך הניתוח – בהתאם לסעיפי שאלה 1

את יתר סעיפי הניתוח יש לבצע על התוצאה של `substitute_actors` באותה מתודולוגיה של שאלה 1, אך כאשר ההגדרה ל"שותפות" מותאמת למושג של שחקנים תחליפיים:

- Precision: לבחור 10 זוגות שהתקבלו ולבדוק ידנית האם הם אכן נראים תחליפיים.
 $Precision = \text{מספר הזוגות שנמצאו נכונים} / 10$
- Recall: לבחור מראש 10 זוגות שנראים תחליפיים ולבדוק כמה מהם הוחזרו על ידי השאילתה. $Recall = \text{מספר הזוגות שהוחזרו} / \text{מספר הזוגות שנבחרו}$
- שיפור Precision: ניתן להעלות את סף ה-Jaccard או לדרוש מספר מינימלי גבוה יותר של שותפים משותפים, כדי להשאיר רק קשרים חזקים יותר.
- שיפור Recall: ניתן להוריד את סף ה-Jaccard או להסתפק בפחות שותפים משותפים, כך שיוחזרו יותר זוגות אפשריים.
- השפעה על מודל המלצה מבוסס שחקנים: Precision גבוה יותר יצמצם המלצות לא רלוונטיות; Recall גבוה יותר יגדיל את מספר המועמדים להמלצה.
- השפעה על מודל המלצה מבוסס שותפים: שחקנים תחליפיים עם רשת שותפים דומה יכולים לשמש להרחבת ההמלצות גם כאשר שני השחקנים עצמם מעולם לא שיחקו יחד.

בדיקת Precision

נבחר מדגם אקראי של 10 זוגות מתוך 111 הזוגות שעברו את הסינון. הסיווג "תחליפיים" הוא שיקול דעת המבוסס על הסרטים, סוגי התפקידים והשותף המשותף; הוא אינו שדה שקיים במסד הנתונים.

הסבר	תחליפיים?	Jaccard	שותפים משותפים	שחקן 2	שחקן 1
שחקן דרמטי ותיק מול שחקנית בתפקידי אופי; השותף המשותף לבדו אינו מצביע על אותו טיפוס תפקיד.	לא	1.000	1	Douglas, Illeana	Gazzara, Ben
שניהם קשורים ל-Jack Nicholson, אך סוג והיקף התפקידים שונים מאוד.	לא	1.000	1	Crothers, Scatman	Cervi, Kenneth
שניהם מזוהים עם תפקידי משנה פיזיים/אקשן סביב Arnold Schwarzenegger ולכן יש דמיון תפקידי סביר.	כן	1.000	1	Tamburro, Charles A.	Columbu, Franco
שחקן אופי בתפקידי משנה מול שחקן מוביל; לא אותו טיפוס תפקיד.	לא	1.000	1	Voight, Jon	Eastin, Steve
שניהם מבצעים קולות ודמויות קוליות/יצורים, ולכן יכולים למלא פונקציה דומה.	כן	1.000	1	Newman, Fred (I)	Hecker, Gary A.
שניהם שחקני משנה חוזרים לצד Clint Eastwood בתפקידי סמכות/אופי קטנים.	כן	1.000	1	Nelson, Lloyd (I)	Mitchum, John
שניהם קשורים ל-Woody Allen, אך סוגי התפקידים והפרופיל שלהם שונים.	לא	1.000	1	Lasser, Louise	Roberts, Tony (I)
שניהם קשורים ל-Boris Karloff, אך אחד שחקן מוביל והשני שחקן משנה.	לא	1.000	1	Mark, Michael (I)	Clive, Colin
שניהם קשורים ל-Warren Beatty, אך אינם ממלאים טיפוס תפקיד דומה.	לא	1.000	1	Christie, Julie (I)	Sorvino, Paul
השותף המשותף Stanley Tucci אינו מספיק כדי להצביע על תחליפיות בין שני פרופילים שונים.	לא	1.000	1	Malloy, Matt (I)	Holm, Ian

$$\text{Precision} = 3 / 10 = 0.30 = 30\%$$

המסקנה היא שהמודל מצליח לייצר מועמדים בעלי רשת שותפים דומה, אך רק 3 מתוך 10 במדגם נראו תחליפיים שימושיים מבחינת סוג התפקיד. לכן Jaccard גבוה לבדו אינו מספיק לזיהוי תחליפיות.

בדיקת Recall

לבדיקת Recall נבחרו מראש 10 זוגות מוכרים שנראים מתאימים לאותו טיפוס תפקיד ושאינם מופיעים יחד בסרטים שבקובץ הנתונים. לאחר מכן נבדק אם המודל החזיר אותם.

הוחזר?	טיפוס תפקיד משוער	שחקן 2	שחקן 1
לא	קומדיה	Williams, Robin (I)	Carrey, Jim
לא	אקשן / קשוח	Van Damme, Jean-Claude	Seagal, Steven (I)
לא	אקשן / מותחן	Gibson, Mel (I)	Willis, Bruce
לא	מותחן / דרמה	Basinger, Kim	Stone, Sharon (I)
לא	דרמה – שחקן מוביל	Costner, Kevin	Hanks, Tom
לא	מותחן / שחקן מוביל	Douglas, Michael (I)	Ford, Harrison (I)
לא	דרמה / מותחן	Stone, Sharon (I)	Pfeiffer, Michelle
לא	קומדיה רומנטית	Bullock, Sandra	Ryan, Meg
לא	שחקן מוביל / דרמה	Costner, Kevin	Cruise, Tom
לא	קומדיה רומנטית	Cusack, John (I)	Grant, Hugh (I)

$$\text{Recall} = 0 / 10 = 0.00 = 0\%$$

אף אחד מעשרת הזוגות לא הוחזר. בבדיקה נמצא שהבעיה מתרחשת עוד לפני תנאי ה-Jaccard: לזוגות האלה אין שותף משותף שנכנס ל-actor_pairs לפי ההגדרה המחמירה של לפחות שלושה סרטים משותפים. לכן הורדת סף ה-Jaccard של מודל התחליפים לבדה לא תפתור את בעיית ה-Recall.

כיצד ניתן לשפר את ה-Precision

ה-Precision במדגם הוא 30%, ולכן צריך להוסיף מידע על דמיון תפקידי ולא להסתמך רק על רשת השותפים. אפשר להשתמש בשדה as_character כדי לחלץ מאפייני תפקידים, להתחשב ב-leading כדי להבדיל בין שחקנים מובילים לשחקני משנה, ולדרוש יותר משותף משותף אחד. כך יקטן הסיכוי ששני שחקנים יקבלו 1 = Jaccard רק משום שלכל אחד מהם יש שותף יחיד זהה.

בנתונים: 106 מתוך 111 התוצאות עברו עם 1 = Jaccard, ולכן העלאת סף Jaccard לבדה כמעט אינה פותרת את בעיית ה-Precision.

כיצד ניתן להעלות את ה-Recall

הורדת סף ה-Jaccard מגדילה את מספר המועמדים: מעל 0.5 מתקבלים 111 זוגות; מעל 0.4 – 231; מעל 0.3 – 362; מעל 0.2 – 524; ומעל 0.1 – 1,126. עם זאת, עשרת הזוגות הידועים עדיין אינם נכנסים, משום שאין להם שותף משותף לפי actor_pairs. לכן צוואר הבקבוק הוא הגדרת השותף המקורית.

מספר זוגות	סף Jaccard
111	מעל 0.50
231	מעל 0.40
362	מעל 0.30
524	מעל 0.20
1,126	מעל 0.10

דרך טובה יותר להעלות Recall היא להשתמש גם במספר השחקנים המשותפים ששני המועמדים שיחקו איתם, גם אם אותם קשרים אינם עומדים בהגדרת "שותף" של שלושה סרטים. בעשרת זוגות הבדיקה, סף של לפחות 20 שחקנים משותפים היה מזהה 9 מתוך 10 הזוגות. זה מראה שספירה מוחלטת יכולה להיות מתאימה יותר מ-Jaccard עבור שחקנים בעלי קריירה גדולה.

בדיקת חלופה על 10 זוגות ה-20 Recall: common co-actors >= 9 מתוך 10 זוגות (90%), לעומת 0% במודל המקורי.

כיצד שחקנים תחליפיים יכולים להעלות את ה-Precision של מודל המלצה מבוסס שחקנים

במקום להמליץ על סרט רק משום שהוא חולק שחקן יחיד עם סרט שהמשתמש אהב, אפשר להעדיף סרט שבו מופיע שחקן שמזוהה כתחליף איכותי לשחקן מהסרט המקורי. כאשר התחליף מבוסס גם על טיפוס תפקיד דומה, הדבר מוסיף תנאי משמעותי יותר ומקטין המלצות מקריות.

כיצד שחקנים תחליפיים יכולים להעלות את ה-Recall של מודל המלצה מבוסס שחקנים

אם משתמש אהב סרט עם שחקן A, מודל ישיר מגיע בעיקר לסרטים שבהם A עצמו מופיע. שחקן תחליפי B מאפשר להרחיב את החיפוש לסרטים שבהם A אינו מופיע כלל אך B כן מופיע. כך מתקבלים סרטים חדשים שהמודל הרגיל לא היה מגיע אליהם, ולכן ה-Recall יכול לעלות.

כיצד העלאת ה-Precision של מודל התחליפים תשפיע על מודל ההמלצה

אם מודל התחליפים מדויק יותר, פחות קשרי תחליפיות שגויים ייכנסו למערכת ולכן גם ההמלצות שמבוססות עליהם יהיו רלוונטיות יותר. מצד שני, סינון מחמיר יקטין את מספר התחליפים הזמינים ועלול להוריד את ה-Recall של מערכת ההמלצה.

כיצד העלאת ה-Recall של מודל התחליפים תשפיע על מודל ההמלצה

כאשר יותר תחליפים אמיתיים מזוהים, מערכת ההמלצה יכולה להציע יותר סרטים שאינם חולקים את אותו שחקן אך כן חולקים טיפוס שחקן דומה. לכן Recall של מערכת ההמלצה צפוי לעלות. עם זאת, אם ההרחבה נעשית באמצעות תנאים מקלים מדי, יתווספו גם תחליפים שגויים וה-Precision עלול לרדת.